

MobileNet

Classificação de Faixa de Preço de Celulares
com Rede Neural MLP

Pipeline completo: EDA → Implementação MLP → Avaliação → Ajuste de Hiperparâmetros → Resultados Finais

95,5% de acurácia · F1-macro 95,51% · 20 features · 2 000 amostras

Autor: Filipe Rangel · May de 2026

01 — Visão Geral do Projeto

Problema · Dataset · Pipeline

PROBLEMA

Dado um conjunto de 20 especificações técnicas de celulares, prever em qual das 4 faixas de preço o aparelho se enquadra:

Classe 0 — Baixo custo
Classe 1 — Custo médio
Classe 2 — Alto custo
Classe 3 — Custo muito alto

DATASET

2 000 amostras de treino
1 000 amostras de teste
20 features numéricas
4 classes — 500 amostras cada

Features principais:
RAM · Potência da bateria ·
Resolução · Câmeras · Memória

EDA

Normalização
StandardScaler

MLP
128→64



Avaliação
92% acc

Tuning
GridSearch

Resultado Final
95,5% acc

02 — Análise Exploratória (EDA)

Distribuição do alvo · Correlação · Top Features




Dataset perfeitamente balanceado: 500 amostras por classe (25% cada).
Elimina viés do modelo e torna a acurácia uma métrica confiável.

RAM é a feature mais correlacionada com faixa_preco ($r \approx 0,92$).
Baixa multicolinearidade entre features — cada variável traz informação independente ao modelo.

02 — EDA: Distribuição das Top 6 Features por Classe

Top 6 Features — Distribuição por Classe



RAM: separação quase perfeita entre classes (~750 / ~1600 / ~2600 / ~3500 MB). Feature mais discriminativa do modelo.
Potência da bateria e resolução: tendência crescente com o preço, mas com sobreposição entre classes adjacentes.
Memória interna e largura da tela: distribuições similares entre classes — baixo poder discriminativo isolado.

03 — Arquitetura MLP e Treinamento


Arquitetura baseline · Curva de aprendizado

Entrada
20 features

Oculto 1
128 neurônios
ReLU

Oculto 2
64 neurônios
ReLU

Saída
4 classes
Softmax





Arquitetura baseline: 20 → 128 → 64 → 4
Ativação: ReLU nas ocultas, Softmax na saída
Otimizador: Adam · Early stopping (paciência=20)
Função de perda: Entropia Cruzada

Convergência rápida nas primeiras 10 iterações.
Perda de treino → ~0,03 | validação estabiliza em ~0,12.
Early stopping interrompeu em ~53 iterações.
Gap aceitável — overfitting leve e controlado.

04 — Avaliação do Modelo Baseline

Matriz de confusão · Métricas por classe





368 / 400 amostras corretas → 92% de acurácia.
Todos os erros ocorrem entre classes adjacentes.
Nenhum salto extremo (Baixo → Muito alto).
Alto custo é a classe mais difícil (13 erros).

Classes extremas (Baixo / Muito alto): F1 = 0,95
Classes do meio (Médio / Alto): F1 = 0,89
Padrão esperado: classes intermediárias têm maior ambiguidade com seus vizinhos.

05 — Ajuste de Hiperparâmetros

RandomizedSearchCV (40 combinações) → GridSearchCV refinado



40 combinações testadas com CV 3-fold.
Top-20 combinações superaram o baseline (0,9198).
Melhor F1-macro em CV: 0,9511
Estratégia em 2 etapas: busca ampla → refinamento.


Configuração vencedora: 256→128 · tanh · $\alpha=0,1$

Baseline → 92,00% acc | 91,98% F1
Tuned → 95,50% acc | 95,51% F1


Ganho: +3,5 p.p. acurácia / +3,53 p.p. F1-macro

06 — Resultados Finais

Importância das features · Predições no conjunto de teste



RAM causa queda de ~68 p.p. de acurácia ao ser permutada.
Potência da bateria: ~21 p.p. | Resolução: ~10 p.p.
As outras 16 features têm importância próxima de zero.
4 features explicam quase toda a capacidade preditiva.



Predições no teste: 256 (Baixo) · 227 (Médio) · 258 (Alto) · 259 (Muito alto)
Distribuição equilibrada e coerente com o treino.
Nenhum viés sistemático em direção a uma classe.

07 — Conclusões e Aprendizados

	Resultado
Dataset	2 000 amostras · 20 features · 4 classes balanceadas
Normalização	StandardScaler ($\mu=0$, $\sigma=1$)
Arquitetura final	20 → 256 → 128 → 4 (tanh + Softmax)
Otimizador	Adam · lr = 0,001 · Early stopping
Regularização L2	$\alpha = 0,1$ (reduz overfitting do baseline)
Acurácia — baseline	92,00%
Acurácia — modelo final	95,50% (+3,5 p.p.)
F1-macro — modelo final	95,51% (+3,53 p.p.)
Feature mais importante	RAM (queda de ~68 p.p. ao permutar)

Dados balanceados simplificam a avaliação

Com 25% por classe, a acurácia é métrica suficiente e não é enganada por classes majoritárias.

RAM domina a predição

Uma única feature explica ~68% da queda de acurácia ao ser removida — feature engineering poderia explorá-la.

Tuning trouxe ganho real

Arquitetura maior (256→128) + tanh + L2 forte ($\alpha=0,1$) superaram o baseline em 3,5 p.p.

Erros são estruturalmente coerentes

Todas as confusões ocorrem entre classes adjacentes: o modelo respeita a ordem ordinal do preço.